Помощник первокурсника ИВТ МИЭМ НИУ ВШЭ

Q&A-система по официальным программам 25 дисциплин 1 курса · 2026/2027

BM25-поиск | RAG | 0 зависимостей | опциональная LLM | источники-ссылки

Рубцов Илья, БИВ265

01 Что делает решение

Отвечает на вопросы

по содержанию дисциплин, формулам оценивания, литературе, преподавателям, срокам и связям между курсами — по любому вопросу первокурсника к программам.

Корпус

25 дисциплин 1 курса ИВТ за 2026/2027: от «Алгебры и геометрии» до проектных семинаров, включая углублённые курсы. Скрейпер скачивает и парсит страницы автоматически.

Показывает источники

Каждый ответ сопровождается ссылками на конкретные разделы официальных программ на hse.ru — ответ всегда проверяем.

Три интерфейса

Веб-чат, CLI и API — всё на стандартной библиотеке Python, запускается одной командой без установки зависимостей.

02 Как это устроено

```
вопрос → нормализация (стемминг + синонимы: «матан», «дискретка», «прога»)
      → BM25-поиск по фрагментам программ (~360 чанков)
      → бусты: упомянутая дисциплина ×2.5 + релевантный раздел («Элементы контроля», «Литература»…)
      → краткий ответ: экстрактивная выжимка или внешняя LLM по найденным фрагментам
      → источники: дисциплина + раздел + ссылка
```

Пайплайн данных

Скрейпер → структурированный JSON (разделы, элементы контроля, литература, метаданные) → чанкинг с очисткой от футера и хлебных крошек.

Гибридный ответ

Офлайн: экстрактивная выжимка ключевых строк. С ключом API — любая OpenAI-совместимая LLM, но строго по найденным фрагментам.

03 Почему такой подход

- **Данные — официальные и структурированные.** Программы на hse.ru уже содержат ответы в явном виде, поэтому **достоверный поиск + выжимка** решают задачу точнее и дешевле, чем генерация «из головы» LLM.
- **Проверяемость важнее красоты.** Студент должен видеть, откуда взят ответ — каждый ответ ссылается на раздел конкретной программы.
- **RLM-схема (retrieval → LLM → sources).** LLM подключается опционально и только переформулирует найденное — галлюцинации сведены к минимуму.
- **Ноль зависимостей.** BM25, стеммер и веб-сервер написаны на чистом Python: решение запускается у любого проверяющего одной командой.
- **Офлайн-режим по умолчанию** — не нужен ключ API, чтобы попробовать.

04 Живой пример

Вопрос

«Как сдаётся математический анализ?»

Ответ помощника

Элементы контроля: Контрольная работа по материалам модуля, Коллоквиум по материалам раздела, Аудиторная работа, Экзамены по итогам 1–3 семестров.

Формула: 0.05 × Аудиторная работа + 0.15 × Коллоквиум + 0.15 × Контрольная работа + 0.5 × Экзамен.

📄 **Математический анализ — Элементы контроля (hse.ru)**

Что здесь работает

- разговорное название курса распознано;
- вопрос про оценивание → поднят раздел «Элементы контроля»;
- собрана и формула, и перечень мероприятий;
- источник — конкретный раздел программы.

Веб-интерфейс

Чат с плашками источников — скриншот в README репозитория.

05 Тестирование: 30 вопросов

Тип	Кол-во	Что проверяли	Результат
Корректная работа	20	содержание, оценивание, литература, преподаватели, кредиты, модули, связи дисциплин, перечень курсов	**18/20 — точный ответ + верный источник**
Демонстрация недостатков	10	вопросы вне корпуса, агрегации, субъективные, генерация, опечатки	**все 10 воспроизводимо показывают границы**

Полные вопросы и ответы: **docs/test_results.md** в репозитории.

06 Где решение ошибается

Вопросы вне корпуса

«В какое время идут пары?», «какие дедлайны?» — расписание и дедлайны не входят в программы. Помощник может **притянуть нерелевантный фрагмент** вместо честного «не знаю».

Агрегация между документами

«Сколько всего кредитов за год?» — нужно просуммировать 25 программ; поиск по фрагментам этого не умеет.

Субъективные вопросы

«Что сложнее: физика или дискретка?» — в корпусе нет основы для сравнения,

Экстрактивный режим

Иногда — набор строк вместо связного ответа; чувствителен к формулировкам, склейке строк и опечаткам («gjxtve yf ujhtj» не распознаётся).

Базовый vs углублённый

При неоднозначной формулировке может смешать версии курса (кредиты 11 у базовой физики и 9 у углублённой).

Генерация контента

«Напиши конспект лекции» — вне задачи; система выдаёт темы, но не учебный материал.

07 Что улучшил бы за два дня

- **1. Семантический поиск.** Заменить/дополнить BM25 эмбеддингами (например, многозязычная sentence-transformers модель): снимет проблемы с синонимами, опечатками и разговорными формулировками.
- **2. Детектор «вне корпуса».** Порог релевантности + классификатор вопроса: честное «этого нет в программах» вместо притянутых фрагментов.
- **3. Агрегации и сравнения.** Прекомпилированная таблица метаданных (кредиты, модули, часы) для ответов типа «сколько кредитов за год».
- **4. LLM-слоу по умолчанию.** Подключить бесплатный OpenAI-совместимый endpoint, чтобы связные ответы были не опцией, а стандартом.
- **5. Многоходовые вопросы.** Декомпозиция вопроса и несколько циклов поиска для «связанных» запросов (пререквизиты → постреквизиты).

08 Итоги и артефакты

Готово

- корпус из 25 программ, автообновление скрейпером;
- поиск + ответы с источниками, офлайн;
- веб-чат, CLI, API — без зависимостей;
- 30 тестовых вопросов с разбором;
- презентация.

Сдаётся

🔗 Открытый репозиторий: исходный код + инструкция запуска (README)

🧪 Результаты тестирования на 30 вопросах: docs/test_results.md

📊 Презентация: docs/presentation.pdf

Запуск за 10 секунд

```
git clone <repo> && cd isct-freshman-assistant
python3 server.py  # → localhost:8000
```

Спасибо за внимание!

Вопросы, код, тесты и презентация — в открытом репозитории

`python3 server.py` `→ localhost:8000`